

FACULDADE IMPACTA TECNOLOGIA

Kayky Paulino Alves dos Santos

Lucas Rodrigues Ferreira

Marcelo Ponciano

Matheus Souza Santiago

Pedro Henrique Rosa Sales

Rhyan Moraes de Azevedo

Sandro de Lima Oliveira

Rede Neural Aplicada à Análise dos Fatores Associados à Severidade do Câncer no
Período de 2015 a 2024

São Paulo

2025

SUMÁRIO

1. INTRODUÇÃO E MOTIVAÇÕES	3
2. ANÁLISE DE DADOS	3
2.1 Análise da Variável Alvo (Pontuação-Alvo de Gravidade)	5
2.2 Correlação entre Variáveis	5
3. APLICAÇÃO DA REDE NEURAL	7
3.1 Resultados do Treinamento da Rede Neural	8
3.2 Importância das Variáveis	10
3.3 Considerações Finais sobre o Modelo	11
4. CONCLUSÃO	12
REFERÊNCIAS	13

1. INTRODUÇÃO E MOTIVAÇÕES

O presente projeto utilizou a base de dados *Global Cancer Patients* (2015–2024), disponível na plataforma Kaggle, publicada por **Zahid Feroze (2024)**, disponível em: [Paciente com Câncer Global de 2015 até 2024 \(Kaggle, 2025\)](#). A base reúne informações sobre pacientes oncológicos de diferentes países, onde possui variáveis demográficas, genéticas, ambientais e comportamentais, permitindo investigar como fatores de risco e hábitos de vida podem influenciar a gravidade dos casos de câncer.

O projeto tem como objetivo identificar padrões e compreender os fatores mais associados à severidade da doença, avaliando o impacto de características como idade, predisposição genética, tabagismo, obesidade, consumo de álcool e exposição à poluição do ar. A análise dos dados busca oferecer insights relevantes sobre o comportamento e os fatores de risco do câncer, contribuindo para a compreensão de como diferentes variáveis podem afetar a gravidade dos quadros clínicos e auxiliando no desenvolvimento de estratégias de prevenção e conscientização em saúde pública.

2. ANÁLISE DE DADOS

A etapa de análise teve como objetivo compreender o comportamento das variáveis presentes na base e identificar fatores associados à severidade do câncer. Durante o pré-processamento, observou-se que algumas variáveis não possuíam relação direta com o nível de severidade da doença ou poderiam introduzir vieses indesejadas no modelo. O custo de tratamento (USD) apresenta forte dependência do país e da estrutura de saúde, o que não reflete a gravidade clínica. Anos vividos descreve tempo de sobrevivência após o tratamento, caracterizando um desfecho e não um fator de risco. Região por país e tipo de câncer também foram removidos por influenciarem mais em diferenças geográficas e estruturais do que nos fatores clínicos que compõem a severidade.

Com isso, manteve-se um conjunto de variáveis mais objetivo e alinhado ao propósito da análise.

- **Variáveis numéricas mantidas:** Idade, Risco Genético, Poluição, Uso de Álcool, Fumante, Nível de Obesidade
- **Variável categórica mantida:** Gênero

Para assegurar uma análise consistente, as variáveis da base foram avaliadas individualmente quanto à sua natureza, amplitude e relevância para o objetivo do estudo. Esse exame inicial permite selecionar os tratamentos estatísticos adequados, como normalização e codificação, além de garantir que apenas atributos coerentes com a predição da severidade sejam utilizados.

A variável Idade é numérica contínua e apresenta valores entre 20 e 89 anos. Por possuir amplitude maior que as demais variáveis numéricas, passa por normalização para evitar que diferenças de escala influenciem o modelo de forma indevida. Risco genético é numérica contínua e varia de zero a dez. Representa a predisposição genética ao câncer e possui relação direta com fatores hereditários. Poluição também varia de zero a dez e reflete a exposição a poluentes ambientais, elemento associado ao aumento de riscos oncológicos.

O uso de álcool representa o nível de consumo de álcool e opera na mesma escala, facilitando a comparação com outras variáveis comportamentais. Smoking indica a intensidade do tabagismo, um dos fatores de risco mais conhecidos para diversos tipos de câncer. Nível de obesidade, igualmente contínua entre zero e dez, reflete o nível de obesidade do paciente, característica associada à progressão de doenças oncológicas. A variável gênero é categórica nominal e não possui ordem natural entre suas categorias. Por essa razão, precisa ser convertida para formato numérico por meio de codificação One Hot.

A faixa etária variou de 20 a 89 anos, com média aproximada de 54 anos. A distribuição não apresentou picos acentuados e permaneceu equilibrada ao longo das faixas intermediárias, o que indica boa representatividade entre adultos e idosos. Os valores médios da severidade entre os gêneros também se mantiveram muito próximos, sugerindo que o gênero, isoladamente, não exerce impacto significativo sobre o desfecho.

Após essa etapa descritiva, prosseguiu-se com a análise das correlações entre as variáveis numéricas, com o objetivo de identificar possíveis relações internas que pudessem interferir no comportamento do modelo preditivo.

2.1 Análise da Variável Alvo (*Target Severity Score*)

A variável Pontuação-Alvo de Gravidade representa o nível de severidade do câncer em uma escala contínua. Antes da construção do modelo, é essencial compreender sua distribuição para avaliar a adequação dos métodos estatísticos e identificar possíveis características que possam influenciar o desempenho da rede neural.

O score varia de 0.9 a 9.16. A média se encontra em aproximadamente 4.95, enquanto a mediana permanece muito próxima desse valor. Essa proximidade indica que a distribuição é relativamente simétrica ao redor do centro. O desvio padrão é de cerca de 1.20, o que revela dispersão moderada dos valores e ausência de variações abruptas.


A análise gráfica da distribuição, por meio de histograma e boxplot, mostra concentração predominante entre os valores quatro e seis, sem presença significativa de caudas longas ou valores extremos que pudessem distorcer o processo de aprendizado. A ausência de outliers relevantes reforça a estabilidade da variável e confirma que seu comportamento é adequado para técnicas de regressão utilizadas em redes neurais.

Com base nessa avaliação, o Pontuação-Alvo de Gravidade apresenta características contínuas, estáveis e bem distribuídas, o que favorece o uso de modelos supervisionados para predição. Essa análise preliminar é indispensável para garantir que o modelo seja construído sobre uma variável alvo compreendida de forma completa.

2.2 Correlação entre Variáveis

A etapa seguinte consistiu em avaliar o grau de correlação entre as variáveis numéricas. Essa verificação é importante porque correlações muito altas entre atributos podem gerar multicolinearidade, o que dificulta o aprendizado do modelo e pode distorcer a importância das variáveis. A matriz de correlação a seguir mostra a relação entre os principais fatores de risco analisados:

FIGURA 1 - Matriz de Correlação entre Fatores de Risco



As correlações entre os fatores de risco apresentam valores baixos, o que indica que cada variável contribui com informações distintas para a análise. A ausência de relações fortes entre atributos como tabagismo, obesidade, consumo de álcool e exposição à poluição mostra que esses fatores não se sobrepõem e representam dimensões diferentes do risco. Isso evita redundância no conjunto de dados e permite que o modelo avalie o impacto individual de cada variável sobre a severidade. A correlação moderada entre o score de severidade e variáveis como predisposição genética e tabagismo reforça o papel relevante desses fatores no agravamento da doença. Dessa forma, a matriz de correlação auxilia na compreensão estrutural do conjunto de dados e estabelece fundamentos importantes para a construção do modelo de rede neural.

3. APLICAÇÃO DA REDE NEURAL

O modelo implementado foi uma Rede Neural Perceptron Multicamadas (MLP) configurada para um problema de regressão. A arquitetura da rede foi composta por duas camadas ocultas, utilizando a função de ativação ReLU, otimizador Adam e função de perda Mean Squared Error (MSE). O conjunto de dados foi dividido em 80% para treino e 20% para teste, e o treinamento inicial foi executado com 200 épocas. No entanto, a curva de perda demonstrou que a rede já havia atingido convergência por volta da 30ª época, tornando desnecessário o prosseguimento até 200. Assim, o treinamento foi reduzido para 30 épocas, o que resultou em menor tempo de execução, consumo computacional e evitou o risco de overfitting.

A rede neural foi construída utilizando o framework TensorFlow/Keras, composta por uma camada de entrada com as variáveis numéricas e categóricas processadas, duas camadas ocultas densas com funções de ativação ReLU e uma camada de saída linear, adequada para problemas de regressão. O modelo foi compilado com o otimizador Adam e a função de perda MSE (Erro Quadrático Médio), tendo como métrica de acompanhamento o MAE (Erro Absoluto Médio).

A Tabela 1 apresenta a arquitetura completa do modelo e os principais hiperparâmetros utilizados durante o treinamento

Tabela 1 – Arquitetura e Hiperparâmetros do Modelo de Rede Neural


Propriedade	Valor
Camada	dense, dense_1, dense_2
Tipo	Dense, Dense, Dense
Neurônios	64, 32, 1
Função de Ativação	relu, relu, linear
Épocas	30
Batch Size	32
Otimizador	Adam
Taxa de Aprendizado	0.001
Função de Perda	mean_squared_error
Métrica Monitorada	MAE
Divisão Treino/Teste	80% / 20%
Normalização	MinMaxScaler (0 a 1)
Codificação Categórica	One Hot Encoding

3.1 Resultados do Treinamento da Rede Neural

O modelo apresentou convergência estável e desempenho consistente nos conjuntos de treino e teste. A avaliação separada das métricas revela MAE de 0.4715, MSE de 0.2986 e RMSE de 0.5464 no treino, enquanto no teste os valores foram MAE de 0.4815, MSE de 0.3079 e RMSE de 0.5549. Os coeficientes de determinação também permaneceram próximos, com R^2 de 0.7932 no treino e 0.7833 no teste, o que confirma a capacidade de generalização da rede sem indícios de overfitting.


A **Figura 2** mostra que, nas primeiras épocas, houve redução acentuada do erro, indicando aprendizado rápido dos padrões presentes nos dados. Após esse ponto inicial, as curvas de treino e teste se mantêm próximas e estáveis, sem afastamentos que indiquem divergência entre os conjuntos. Esse comportamento confirma a estabilidade no processo de otimização.

FIGURA 2 - Curva de Perda (Loss)



A **Figura 2** reforça essa estabilidade. Os pontos aparecem concentrados ao longo da diagonal, demonstrando forte alinhamento entre as previsões da rede e os valores observados. Essa distribuição indica que o modelo foi capaz de capturar relações significativas entre os fatores analisados e a severidade do câncer.

FIGURA 3 - Dispersão entre Valores Reais e Preditos




As métricas apresentaram valores muito próximos entre treino e teste, e a curva de perda mostrou comportamento estável sem afastamento entre os conjuntos. Além disso, o gráfico de dispersão indicou alta coerência entre valores reais e previstos. Esses elementos confirmam que o modelo não apresenta indícios de overfitting e mantém capacidade satisfatória de generalização.

3.2 Importância das Variáveis

Para compreender o impacto de cada fator no modelo, foi realizada a análise de importância relativa das variáveis a partir dos pesos médios da rede neural. A Figura a seguir mostra as dez variáveis com maior influência sobre a severidade prevista.

FIGURA 4 - Importância das Variáveis no Modelo de Rede Neural



As variáveis **Risco Genético** e **Fumante** se destacaram como as de maior relevância, seguidas por Nível de Obesidade, Poluição, Uso de Álcool e Idade. Isso sugere que tanto fatores genéticos quanto comportamentais exercem papel determinante no aumento da severidade da doença;

3.3 Considerações Finais sobre o Modelo

Durante o desenvolvimento, algumas decisões de modelagem foram essenciais para a estabilidade e desempenho obtidos:

- **Redução do número de épocas de 200 para 30**, com base na estabilização da curva de perda.
- **Remoção de variáveis não diretamente relacionadas à severidade** (como custo de tratamento e país), evitando que o modelo aprendesse relações artificiais.
- **Manutenção apenas das variáveis mais relevantes e independentes**, reduzindo ruído e melhorando a interpretabilidade.

4. CONCLUSÃO

O presente estudo teve como objetivo desenvolver e avaliar um modelo de rede neural artificial (MLP) para a predição da severidade do câncer com base em fatores de risco clínicos e comportamentais.

A partir da análise exploratória dos dados, foi possível compreender a distribuição e a influência de variáveis como **idade, risco genético, obesidade, tabagismo, consumo de álcool e poluição do ar** sobre o desfecho estudado.

A análise da curva de perda mostrou uma **convergência rápida e estável**, evidenciando que a rede aprendeu de forma eficiente e sem sobreajuste. Os gráficos de dispersão confirmaram a **alta correlação entre valores reais e preditos**, enquanto a distribuição simétrica dos resíduos indicou que os erros do modelo ocorrem de maneira aleatória, sem viés sistemático. Além disso, a análise de importância das variáveis revelou que **fatores genéticos e hábitos de vida**, especialmente **tabagismo, obesidade e consumo de álcool**, estão entre os mais relevantes para a severidade da doença, reforçando a coerência do modelo em relação a evidências da literatura médica.

De modo geral, os resultados demonstram que as redes neurais são uma ferramenta promissora para apoiar a análise de riscos e a tomada de decisão em contextos de saúde pública. Além disso, observa-se que a adoção de um **estilo de vida saudável** contribui para a redução da severidade do câncer, enquanto a **predisposição genética** eleva significativamente esse risco. Dessa forma, reforça-se a importância de **programas de conscientização e exames preventivos periódicos** para indivíduos com histórico familiar da doença.

REFERÊNCIAS

FEROZE, Zahid. *Global Cancer Patients (2015–2024)*. Kaggle, 2024.

Disponível

em

:<https://www.kaggle.com/datasets/zahidmughal2343/global-cancer-patients-2015-2024>. Acesso em: 01 nov. 2025.

AZEVEDO, Rhyan Morais de; FERREIRA, Lucas Rodrigues; SANTOS, Kayky Paulino Alves dos; PONCIANO, Marcelo Henrique da Cunha; SOUZA, Matheus Santiago; SALES, Pedro Henrique Rosa; OLIVEIRA, Sandro de Lima.

AP2 – Machine Learning: Análise dos Fatores Associados à Severidade de Câncer (2015–2024). Google Colab, 2024.

Disponível

em:

<https://colab.research.google.com/drive/19dncYeJN77y8edFMEJY7dPRIT4NBR4D9?usp=sharing>. Acesso em: 01 nov. 2025.

PROVOST, Foster; FAWCETT, Tom. *Data Science para Negócios: O que você precisa saber sobre mineração de dados e pensamento analítico de dados*. Rio de Janeiro: Alta Books, 2014.

ZHENG, Alice; CASARI, Amanda. *Feature Engineering for Machine Learning: Principles and Techniques for Data Scientists*. Sebastopol, CA: O'Reilly Media, 2018.

GÉRON, Aurélien. *Mãos à Obra: Aprendizado de Máquina com Scikit-Learn e TensorFlow*. 3. ed. Rio de Janeiro: Alta Books, 2023.