

Rede Neural Aplicada à Análise dos Fatores Associados à Severidade do Câncer

Período de 2015 a 2024

Kayky Paulino Alves dos Santos • Lucas Rodrigues Ferreira • Marcelo Ponciano • Matheus Souza Santiago • Pedro Henrique Rosa Sales • Rhyann Moraes de Azevedo • Sandro de Lima Oliveira

FACULDADE IMPACTA TECNOLOGIA



Introdução e Motivações

Este projeto utilizou a base de dados *Global Cancer Patients (2015–2024)*, disponível na plataforma Kaggle, publicada por Zahid Feroze (2024). A base reúne informações sobre pacientes oncológicos de diferentes países, incluindo variáveis demográficas, genéticas, ambientais e comportamentais.

O objetivo é identificar padrões e compreender os fatores mais associados à severidade da doença, avaliando o impacto de características como idade, predisposição genética, tabagismo, obesidade, consumo de álcool e exposição à poluição do ar.

A análise busca oferecer insights relevantes sobre o comportamento e os fatores de risco do câncer, contribuindo para estratégias de prevenção e conscientização em saúde pública.



Análise de Dados

A etapa de análise teve como objetivo compreender o comportamento das variáveis presentes na base e identificar fatores associados à severidade do câncer. Durante o pré-processamento, algumas variáveis foram removidas por não possuírem relação direta com o nível de severidade ou por introduzirem vieses indesejados.

Variáveis Removidas

- Custo de tratamento (dependência geográfica)
- Anos vividos (desfecho, não fator de risco)
- Região por país (diferenças estruturais)
- Tipo de câncer (variação geográfica)

Variáveis Mantidas

Numéricas: Idade, Risco Genético, Poluição, Uso de Álcool, Fumante, Nível de Obesidade

Categórica: Gênero (codificação One Hot)

A variável Idade apresenta valores entre 20 e 89 anos, com média aproximada de 54 anos. A distribuição permaneceu equilibrada ao longo das faixas intermediárias, indicando boa representatividade entre adultos e idosos. Os valores médios da severidade entre os gêneros mantiveram-se muito próximos, sugerindo que o gênero, isoladamente, não exerce impacto significativo sobre o desfecho.

Análise da Variável Alvo

Pontuação-Alvo de Gravidade

A variável representa o nível de severidade do câncer em uma escala contínua. O score varia de 0.9 a 9.16, com média em aproximadamente 4.95 e mediana muito próxima desse valor, indicando distribuição relativamente simétrica.

O desvio padrão de cerca de 1.20 revela dispersão moderada dos valores, sem variações abruptas. A análise gráfica mostra concentração predominante entre os valores quatro e seis, sem presença significativa de outliers.

0.9-9.16

Variação

Amplitude do score de severidade

4.95

Média

Valor médio da severidade

1.20


Desvio Padrão

Dispersão moderada dos valores

Correlação entre Variáveis

A matriz de correlação mostra relações entre os principais fatores de risco analisados. As correlações apresentam valores baixos, indicando que cada variável contribui com informações distintas para a análise.

A ausência de relações fortes entre atributos como tabagismo, obesidade, consumo de álcool e exposição à poluição mostra que esses fatores não se sobrepõem e representam dimensões diferentes do risco. A correlação moderada entre o score de severidade e variáveis como predisposição genética e tabagismo reforça o papel relevante desses fatores no agravamento da doença.



Aplicação da Rede Neural

O modelo implementado foi uma Rede Neural Perceptron Multicamadas (MLP) configurada para um problema de regressão. A arquitetura foi composta por duas camadas ocultas, utilizando a função de ativação ReLU, otimizador Adam e função de perda Mean Squared Error (MSE).

01

Divisão dos Dados

80% para treino e 20% para teste

02

Treinamento Inicial

200 épocas planejadas, convergência na 30^a

03

Otimização

Redução para 30 épocas, evitando overfitting

Propriedade	Valor
Camada	dense, dense_1, dense_2
Tipo	Dense, Dense, Dense
Neurônios	64, 32, 1
Função de Ativação	relu, relu, linear
Épocas	30
Batch Size	32
Otimizador	Adam
Taxa de Aprendizado	0.001
Função de Perda	mean_squared_error
Métrica Monitorada	MAE
Divisão Treino/Teste	80% / 20%
Normalização	MinMaxScaler (0 a 1)
Codificação Categórica	One Hot Encoding

A rede neural foi construída utilizando o framework TensorFlow/Keras, composta por uma camada de entrada com as variáveis processadas, duas camadas ocultas densas com funções de ativação ReLU e uma camada de saída linear, adequada para problemas de regressão. O modelo foi compilado com o otimizador Adam e a função de perda MSE, tendo como métrica de acompanhamento o MAE.

Resultados do Treinamento

O modelo apresentou convergência estável e desempenho consistente nos conjuntos de treino e teste. A avaliação separada das métricas confirma a capacidade de generalização da rede sem indícios de overfitting.

Métricas de Treino

- MAE: 0.4715
- MSE: 0.2986
- RMSE: 0.5464
- R^2 : 0.7932

Métricas de Teste


- MAE: 0.4815
- MSE: 0.3079
- RMSE: 0.5549
- R^2 : 0.7833

Curva de Perda (Loss)

Nas primeiras épocas, houve redução acentuada do erro, indicando aprendizado rápido dos padrões. Após esse ponto inicial, as curvas de treino e teste se mantêm próximas e estáveis, sem afastamentos que indiquem divergência.

Dispersão entre Valores


Os pontos aparecem concentrados ao longo da diagonal, demonstrando forte alinhamento entre as previsões da rede e os valores observados.



As métricas apresentaram valores muito próximos entre treino e teste, e a curva de perda mostrou comportamento estável. O gráfico de dispersão indicou alta coerência entre valores reais e previstos, confirmando que o modelo não apresenta indícios de overfitting e mantém capacidade satisfatória de generalização.

Importância das Variáveis

Para compreender o impacto de cada fator no modelo, foi realizada a análise de importância relativa das variáveis a partir dos pesos médios da rede neural. A figura mostra as dez variáveis com maior influência sobre a severidade prevista.



Risco Genético

Maior relevância no modelo

Tabagismo

Segundo fator mais importante

Obesidade

Terceiro em relevância

As variáveis *Genetic_Risk* e *Smoking* se destacaram como as de maior relevância, seguidas por *Obesity_Level*, *Air_Pollution*, *Alcohol_Use* e *Age*. Isso sugere que tanto fatores genéticos quanto comportamentais exercem papel determinante no aumento da severidade da doença.



Considerações sobre o Modelo

Durante o desenvolvimento, algumas decisões de modelagem foram essenciais para a estabilidade e desempenho obtidos:

1

Otimização de Épocas

Redução do número de épocas de 200 para 30, com base na estabilização da curva de perda, resultando em menor tempo de execução e consumo computacional.

2

Seleção de Variáveis

Remoção de variáveis não diretamente relacionadas à severidade (como custo de tratamento e país), evitando que o modelo aprendesse relações artificiais.

3

Redução de Ruído

Manutenção apenas das variáveis mais relevantes e independentes, reduzindo ruído e melhorando a interpretabilidade do modelo.

Conclusão

O presente estudo desenvolveu e avaliou um modelo de rede neural artificial (MLP) para a predição da severidade do câncer com base em fatores de risco clínicos e comportamentais. A partir da análise exploratória dos dados, foi possível compreender a distribuição e a influência de variáveis como idade, risco genético, obesidade, tabagismo, consumo de álcool e poluição do ar sobre o desfecho estudado.

Convergência Estável

A curva de perda mostrou aprendizado eficiente sem sobreajuste

Fatores Relevantes

Genética e hábitos de vida são determinantes



Alta Correlação

Forte alinhamento entre valores reais e preditos

Resíduos Simétricos

Erros ocorrem de maneira aleatória, sem viés sistemático

Os resultados demonstram que as redes neurais são uma ferramenta promissora para apoiar a análise de riscos e a tomada de decisão em contextos de saúde pública.

Observa-se que a adoção de um **estilo de vida saudável** contribui para a redução da severidade do câncer, enquanto a **predisposição genética** eleva significativamente esse risco. Dessa forma, reforça-se a importância de **programas de conscientização e exames preventivos periódicos** para indivíduos com histórico familiar da doença.

Referências

FEROZE, Zahid. *Global Cancer Patients (2015–2024)*. Kaggle, 2024. Disponível em:

<https://www.kaggle.com/datasets/zahidmughal2343/global-cancer-patients-2015-2024>. Acesso em: 01 nov. 2025.

AZEVEDO, Rhyan Moraes de; FERREIRA, Lucas Rodrigues; SANTOS, Kayky Paulino Alves dos; PONCIANO, Marcelo Henrique da Cunha; SOUZA, Matheus Santiago; SALES, Pedro Henrique Rosa; OLIVEIRA, Sandro de Lima. *AP2 – Machine Learning: Análise dos Fatores Associados à Severidade de Câncer (2015–2024)*. Google Colab, 2024. Disponível em:

<https://colab.research.google.com/drive/19dncYeJN77y8edFMEJY7dPRIT4NBR4D9?usp=sharing>. Acesso em: 01 nov. 2025.

PROVOST, Foster; FAWCETT, Tom. *Data Science para Negócios: O que você precisa saber sobre mineração de dados e pensamento analítico de dados*. Rio de Janeiro: Alta Books, 2014.

ZHENG, Alice; CASARI, Amanda. *Feature Engineering for Machine Learning: Principles and Techniques for Data Scientists*. Sebastopol, CA: O'Reilly Media, 2018.

GÉRON, Aurélien. *Mãos à Obra: Aprendizado de Máquina com Scikit-Learn e TensorFlow*. 3. ed. Rio de Janeiro: Alta Books, 2023.